


Granja de modelos de IA

Trabajo final

Francisco Javier Pérez García
Manuel Ruiz Aguilar
Gabriel Francisco Sánchez Muñoz

Servidores Web de Altas Prestaciones, ICAR, ETSIIT, UGR

Introducción



docker

¿IA + Granja?

Fundamentos

- **Docker y Docker Compose:** Contenerización.
- **Ollama + Qwen3.5 0.8b:** Software para ejecutar modelos IA.
- **LiteLLM:** Balanceador para IAs.
- **Redis Stack:** Almacenamiento de caché semántico.


$$\text{sim}(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \cdot \|\vec{b}\|} \in [-1, 1]$$

- **Nginx:** Proxy inverso.

Objetivos

- Granja IA organizada por funcionalidad y reproducible.
- Distribuir trabajo con balanceo de carga.
- Reducir la carga con consulta al caché semántico.
- Usar un proxy de alto rendimiento con respuestas en *streaming*.

Arquitectura



Arquitectura del sistema: flujo de peticiones entre componentes.

Implementación

- **docker-compose.yml**: red *semantic-cache-net*, *depends_on*, puertos, comandos, variables de entorno, scripts, healthchecks y volúmenes.
- **configv2.yaml**: dos entradas para inferencia y una para embeddings, con sus debidos parámetros de APIs, el umbral de similitud a 0.85, tamaño de vector y tiempo de vida en caché.
- **nginx.conf**: redirige a LiteLLM:4000, permite *streaming* y extiende timeouts.

Análisis de rendimiento


Resultados de `test_litellm.py`

HITs esperados (w) y obtenidos (r).

Grupo	Pet.	HITs (w)	HITs (r)	Acierto
Duplicados exactos	20	10	10	100 %
Paráfrasis Geografía	15	10	10	100 %
Paráfrasis Ciencia	15	10	4	40 %
Paráfrasis Historia	15	10	7	70 %
Relacionados distintos	9	0	0	—
No relacionados	5	0	1	—
Balanceo de carga	10	0	0	—

Análisis de rendimiento

Resultados de test_litellm.py



Factor de aceleración: 191,5×

Conclusiones

Cumplimiento de objetivos

Cumplido	Limitación
Aceleración de 191.5x en latencia con caché.	El umbral fijo no se adapta completamente y la latencia se limita con la CPU, y se aumenta con el paso intermedio de consultar caché.
Buena detección de paráfrasis en dominios con vocabulario diferenciado.	En ciencia; por ejemplo; no.
Balanceo equitativo.	Contamos solo con 2 réplicas de inferencia.
Cambios en la configuración independientes y sencillos.	—

Conclusiones

Trabajo futuro

- Umbral adaptativo.
- Caché multinivel.
- Más réplicas, con escalado dinámico.
- Aceleración por hardware.
- Detección de cuellos de botella con Locust.
- Monitorización con Prometheus y Grafana.

Red:

- Reglas según IP.
- Certificado SSL en Nginx.
- Optimización de envío según parámetros concretos.

FIN